

Hack II

データ定義・取得仕様書

計測データの定義／取得元／算出式／取得範囲の詳細定義

version 1.0（別紙B）／2026.06.12

本書の位置づけ：本書は「開発総合仕様書 v2.0」の別紙Bであり、Hackall（AI検索計測）が「**どのデータを・どこから・どう取得し・どう加工して保存・表示するか**」をフィールド単位で定義したデータ仕様書です。エンジニアがDB スキーマ設計・API パース実装・集計ロジック実装に着手できる粒度を目指しています。本書と総合仕様書が矛盾する場合は総合仕様書 v2.0 を優先します。

発注元	Regalis Japan Group 株式会社
担当	代表取締役社長 井上 幹太
作成日	2026年6月12日
版数	v1.0（別紙B・データ定義特化）
親文書	Hack II 開発総合仕様書 v2.0
機密区分	社外秘（開発パートナー限定開示）

目次

1. データの全体像と原則
2. 取得元：エンジン別レスポンスのマッピング
3. 取得範囲（スコープ・上限・頻度・保持）
4. データ辞書（テーブル別カラム定義）
5. 導出・算出データの定義（計算式）
6. ブランド言及判定ロジックの定義
7. データのライフサイクルと状態遷移
8. 画面・CSVに出力するデータ項目
9. 取得しないデータ（明示的スコープ外）
10. 検収時に確認するデータ要件

1. データの全体像と原則

1.1 大原則


本ツールは自社サーバーのアクセスログを一切使いません。計測の入力は「登録キーワード」、取得元は「AI検索エンジンのAPIレスポンス」です。AIが返す①回答本文（`answer_text`）と②出典URL配列（`citations`）の2つを解析して全データを生成します。

1.2 データの3分類

本書では全データを取得方法で3種類に分類して扱います。凡例は本書全体で共通です。

RAW APIから直接取得・保存する生データ **DERIVED** RAWから計算して導出する集計データ **LATER** 今回は取得しない（将来）

1.3 データ生成のパイプライン



1.4 計測の単位（粒度）

単位	意味
1計測レコード	「1キーワード × 1エンジン × 1実行時刻」で1件。最小粒度。
1スナップショット	あるプロジェクトの週次バッチ1回分（全キーワード×全エンジン）。
1プロジェクト	代理店が管理する1クライアントサイト。計測・集計・課金の単位。

2. 取得元：エンジン別レスポンスのマッピング

エンジンごとにレスポンス構造が異なります。各エンジンのどのフィールドを共通スキーマ `{url, position}` / `answer_text` に対応させるかを定義します。※APIの仕様・フィールド名は変わり得るため、実装時に各社の最新公式ドキュメントで確認してください【要最新確認】。

2.1 Perplexity (Sonar API) MUST・主軸

共通スキーマ	Perplexityレスポンスの取得元 (想定パス)
<code>answer_text</code>	<code>choices[0].message.content</code>
<code>citations[].url</code>	<code>citations[]</code> または <code>search_results[].url</code> の配列
<code>citations[].position</code>	上記配列のインデックス (0始まり→1始まりに正規化)
<code>citations_raw</code>	レスポンス全体をそのまま JSONB 保存

2.2 Google Gemini API (Grounding) MUST・第2軸

共通スキーマ	Geminiレスポンスの取得元 (想定パス)
<code>answer_text</code>	<code>candidates[0].content.parts[].text</code>
<code>citations[].url</code>	<code>candidates[0].groundingMetadata.groundingChunks[].web.uri</code>
<code>citations[].position</code>	<code>groundingChunks</code> 配列のインデックス (1始まりに正規化)
(補足)	<code>groundingSupports</code> でテキスト内の参照位置も取得可。初期は未使用で可。

Gemini は **Grounding with Google Search** を有効化しないと出典URLが返りません。必ず有効化前提で実装してください。
Grounding検索は課金対象 (§ 3 と総合仕様書 § 4.4 参照) 。

2.3 OpenAI (Responses API + web_search) SHOULD

共通スキーマ	OpenAIレスポンスの取得元 (想定パス)
<code>answer_text</code>	出力メッセージの本文テキスト
<code>citations[].url</code>	本文 <code>annotations</code> 内の <code>url_citation.url</code>
<code>citations[].position</code>	<code>annotation</code> の出現順

2.4 正規化後の共通スキーマ (Adapterの出力契約)

```
{
  "engine": "perplexity | gemini | openai",
  "answer_text": "AIの回答本文 (全文)",
  "citations": [
    { "url": "https://example.com/page", "position": 1 },
    { "url": "https://competitor.com/x", "position": 2 }
  ],
  "raw_response": { ... } // 生レスポンスをそのまま (→citations_rawへ)
}
```

判定・集計ロジックは**この共通スキーマのみに依存**させ、エンジン固有のパースは各Adapterに閉じ込めます。これによりエンジン追加時も集計コードを変更不要にします。

3. 取得範囲（スコープ・上限・頻度・保持）

3.1 ハードリミット（APIコスト暴走防止・MUST）

システム側でバリデーションを実装し、以下を超える登録を不可とします。

項目	上限	根拠
1プロジェクトあたりキーワード数	最大20件	API原価の上限を固定するため
1プロジェクトあたり競合ドメイン数	最大3社	SOV比較に必要十分
計測エンジン数（MVP）	2エンジン（Perplexity+ Gemini）	OpenAIは予算次第で+1
計測頻度	週次（既定）+手動実行ボタン	推移計測に必要十分

上限値はプラン設計で将来変更可能にしておくことが望ましいが、MVPでは上記固定値で構いません。

3.2 1スナップショットあたりのAPIコール数

コール数 = キーワード数 × エンジン数
例) 20キーワード × 2エンジン = 40コール/プロジェクト/週
月次（4週）= 160コール/プロジェクト

3.3 レートリミット対応（MUST）

複数プロジェクト × 複数エンジンの週次バッチが各社のRate Limitに同時集中しないよう、**Cloudflare Queues** 等で逐次化し、**スリープ（待機）を挟んで裏でゆっくり回す**方式とします。即時性は不要です。失敗時はリトライ（指数バックオフ）で対応してください。

3.4 データ保持方針

データ	保持
citation_results（計測結果・JSONB含む）	削除しない（推移分析・再集計のため蓄積）
citations_raw（生レスポンス）	丸ごと保存。将来「競合の何が引用されたか」等の再集計に使用
個人情報	取得しない（後述 §9）

「データは捨てずに貯める」が原則。特に `citations_raw` を残すことで、後から新しい指標を過去分まで遡って再計算できます。

4. データ辞書（テーブル別カラム定義）

論理定義です。型・制約の最終決定はエンジニアにお任せしますが、定義・取得元・分類は本書に従ってください。分類凡例：RAW DERIVED

4.1 accounts（アカウント＝代理店／事業会社）

カラム	型	分類	定義・取得元・例
id	UUID	RAW	主キー。自動採番
name	VARCHAR	RAW	代理店名／会社名。登録時入力。例「〇〇広告株式会社」
plan	VARCHAR	RAW	契約プラン。例 standard / agency
created_at	TIMESTAMPTZ	RAW	作成日時

4.2 users（ログインユーザー）

カラム	型	分類	定義・取得元・例
id	UUID	RAW	主キー（Supabase Auth 連携）
account_id	UUID	RAW	所属アカウントへの外部キー
email	VARCHAR	RAW	ログインID。認証はSupabase Authに委譲
role	VARCHAR	RAW	権限。admin / member（MVPは簡易で可）

4.3 projects（プロジェクト＝1クライアントサイト）

カラム	型	分類	定義・取得元・例
id	UUID	RAW	主キー
account_id	UUID	RAW	所属アカウントへの外部キー
name	VARCHAR	RAW	プロジェクト名。例「A社サイト計測」
target_domain	VARCHAR	RAW	計測対象の自社ドメイン。例 client-a.com。引用判定の基準
brand_terms	JSONB / 配列	RAW	言及判定するブランド名・表記ゆれの配列。例 ["Regalis","リガリス"]
created_at	TIMESTAMPTZ	RAW	作成日時

4.4 competitors（競合ドメイン／競合ブランド）

カラム	型	分類	定義・取得元・例
id	UUID	RAW	主キー
project_id	UUID	RAW	プロジェクトへの外部キー
domain	VARCHAR	RAW	競合ドメイン。例 competitor-b.com（最大3件）
brand_terms	JSONB / 配列	RAW	競合ブランド名（言及比較用・任意）

4.5 keywords（監視キーワード）

カラム	型	分類	定義・取得元・例
id	UUID	RAW	主キー

project_id	UUID	RAW	プロジェクトへの外部キー
keyword	VARCHAR	RAW	計測キーワード。例「家族信託 費用」（最大20件）
query_template	TEXT	RAW	AIへ送る質問文の雛形。例「{keyword}について教えて」
monthly_search_volume	INTEGER	RAW	月間検索数。機会損失額の算出に使用。手入力（MVP）。任意
cv_unit_price	INTEGER	RAW	CV単価（円）。機会損失額の算出に使用。手入力。任意
is_active	BOOLEAN	RAW	計測ON/OFF

4.6 citation_results（計測結果＝心臓部）

「1キーワード × 1エンジン × 1実行」で1レコード。本ツールの中核テーブルです。

カラム	型	分類	定義・取得元・例
id	UUID	RAW	主キー
keyword_id	UUID	RAW	キーワードへの外部キー
ai_engine	VARCHAR	RAW	計測エンジン。perplexity / gemini / openai
snapshot_date	DATE	RAW	計測基準日（週次バッチ単位）。例 2026-07-06
queried_at	TIMESTAMPTZ	RAW	実際にAPIを実行した時刻
answer_text	TEXT	RAW	AI回答本文の全文。言及判定・証跡・将来分析に使用
citations_raw	JSONB	RAW	生レスポンスを丸ごと保存。再集計の元データ
is_cited	BOOLEAN	DERIVED	citations内に target_domain が含まれるか（T/F）
cited_url	VARCHAR	DERIVED	引用された自社URL（複数時は最上位 or 配列）
cited_position	INTEGER	DERIVED	出典内での順位（1始まり）。未引用時はNULL
is_mentioned	BOOLEAN	DERIVED	answer_text に brand_terms のいずれかが含まれるか
mention_count	INTEGER	DERIVED	本文中のブランド名出現回数
competitor_mentions	JSONB	DERIVED	競合ブランドの言及有無・回数。例 {"competitor-b":2}
total_citation_slots	INTEGER	DERIVED	このレコードのcitations件数（出典総枠数）

設計判断：is_cited 等は保存時に判定して持たせる（クエリ高速化）か、citations_raw から都度算出するか、いずれでも可。本書では「保存時に判定列を埋める」ことを推奨します。

4.7 snapshots（任意・週次集計の親テーブル）

カラム	型	分類	定義・取得元・例
id	UUID	RAW	主キー
project_id	UUID	RAW	プロジェクトへの外部キー
snapshot_date	DATE	RAW	計測基準日
citation_rate	NUMERIC	DERIVED	その週の引用率（§ 5.2）
mention_rate	NUMERIC	DERIVED	その週の言及率（§ 5.3）
share_of_voice	NUMERIC	DERIVED	自社のSOV（§ 5.1）

snapshots は集計をキャッシュする任意テーブル。citation_results から都度集計する実装でも構いません。

5. 導出・算出データの定義（計算式）

すべて citation_results（RAW）から計算します。集計はエンジン横断（全エンジン合算）と、エンジン別の両方を出せる設計が望ましいです。

5.1 引用シェア（Share of Voice / SOV） MUST

```
domain_citation_count = あるドメインが全計測の出典に登場した回数の合計
total_citation_slots = Σ（各計測レコードの citations 件数）

share_of_voice(%) = domain_citation_count ÷ total_citation_slots × 100
```

自社・各競合それぞれについて算出し、降順に並べた順位を rank_among_competitors とします。

5.2 引用率（Citation Rate） MUST

```
weekly_citation_rate(%) = is_cited が true の計測数 ÷ 全計測数 × 100
（プロジェクト単位・週次。エンジン別にも算出可）
```

5.3 言及率（Mention Rate） MUST

```
weekly_mention_rate(%) = is_mentioned が true の計測数 ÷ 全計測数 × 100
```

5.4 前週比（Delta） MUST

```
delta_vs_previous = 今週の値 - 先週の値（ポイント差）
（citation_rate・mention_rate・share_of_voice それぞれに適用）
```

5.5 機会損失額（Opportunity Loss） MUST

```
opportunity_loss_yen =
（競合トップのSOV - 自社のSOV）÷ 100
× monthly_search_volume
× cv_unit_price
```

営業の核となる数字です。ただし monthly_search_volume と cv_unit_price は手入力（推定値）に依存するため、画面・CSVには「入力値に基づく試算であり保証値ではない」旨の注記を併記してください。値が未入力の場合は機会損失額は「—（未算出）」表示とします。

5.6 引用元ソースランキング SHOULD

キーワード群全体の citations を集計し、
ドメイン別の登場回数を降順表示（自社・競合以外も含む）
→「AIが今信頼しているドメインTOP10」を提示

6. ブランド言及判定ロジックの定義

6.1 判定の基本

```
for term in project.brand_terms:
    if term が answer_text に含まれる:
        is_mentioned = true
        mention_count += 出現回数
競合についても competitor.brand_terms で同様に判定 → competitor_mentions
```

6.2 表記ゆれの扱い（初期スコープ）

対応	MVP	方針
完全一致（登録語そのまま）	MUST	brand_terms に登録された文字列での単純包含判定
大文字小文字の同一視	MUST	英字は小文字化して比較
全角・半角の同一視	SHOULD	正規化（NFKC等）後に比較。工数次第で初期実装
カナ・かな・ローマ字の揺れ	LATER	brand_terms に手動で別表記を登録して回避（初期）
同名他社の誤検知排除	LATER	初期は許容。将来は文脈判定で対応

初期は「表記ゆれは brand_terms に複数登録して吸収する」運用とし、ロジックは単純包含＋小文字化に留めて工数を抑えます。全角半角正規化は可能なら入れてください。

7. データのライフサイクルと状態遷移

フェーズ	発生するデータ
登録時	accounts / users / projects / competitors / keywords を作成
バッチ実行時	citation_results を新規INSERT（RAW取得→判定列を算出して保存）
集計時	SOV・各rate・delta・機会損失額を算出（snapshotsへ保存 or 都度計算）
表示・出力時	ダッシュボード描画・CSVエクスポート（読み取りのみ）
蓄積	citation_results は削除せず累積（推移・再集計の資産）

8. 画面・CSVに出力するデータ項目

8.1 ダッシュボード（営業提示用）

表示要素	出力するデータ
KPIカード	引用率・言及率・自社SOV・機会損失額（プロジェクト単位・今週）
競合比較バー	自社／競合のSOV（降順）。エンジン別フィルタ可
推移グラフ	引用率・SOVの週次推移（snapshot_date 系列）
キーワード別明細	keyword・engine・is_cited・cited_url・is_mentioned・answer_text（証跡）
引用元ランキング SHOULD	ドメイン別登場回数TOP

8.2 CSV出力（MUST）

計測明細を1行＝1計測レコードでエクスポート。最低限の列：

```
snapshot_date, project, keyword, ai_engine, is_cited, cited_url,
cited_position, is_mentioned, mention_count, share_of_voice(自社),
competitor_top_sov, opportunity_loss_yen
```

9. 取得しないデータ（明示的スコープ外）

取得しないデータ	理由
自社サイトのアクセスログ／PV	本ツールはAPI出典ベース。サーバーログは使わない
エンドユーザーの個人情報	計測対象は「ブランド×キーワード」。個人を扱わない
センチメント（言及のポジ/ネガ）	LLM追加呼び出しでコスト増。言及計測が動いてから（LATER）
L4改善示唆（losing_keywords / gap_pages）	総合仕様書通りスコープ外（LATER）
ChatGPTコンシューマ画面の回答	APIで再現不可。対象外
検索ボリュームの外部自動取得	外部データ購入が必要。MVPは手入力（LATER）

10. 検収時に確認するデータ要件

以下がすべて満たされた状態をデータ面の検収条件とします（総合仕様書 § 7.2 を補完）。

- 登録キーワードに対し週次バッチが走り、**Perplexity と Gemini の両エンジン**で citation_results が ai_engine 別に INSERTされる
- 各レコードに citations_raw（JSONB生データ）が保存されている
- 出典に target_domain がある場合 is_cited=true、cited_position が正しく記録される
- 本文に brand_terms がある場合 is_mentioned=true、mention_count が記録される
- SOV・引用率・言及率・前週比・機会損失額が § 5 の式どおり算出され画面表示される
- ハードリミット（KW20・競合3）超過の登録が弾かれる
- 計測明細が § 8.2 の列でCSV出力できる

本書未定義のデータ項目・型・制約は、発注者・受注者間の協議の上で決定します。記載が総合仕様書 v2.0 と矛盾する場合は総合仕様書を優先します。